BÁO CÁO BÀI THỰC HÀNH LAB 2

ĐẶC TRƯNG TIẾNG NÓI VÀ NHẬN DẠNG BẰNG DTW

CSE457 - Xử lý âm thanh và tiếng nói

Khoa Công nghệ thông tin - Trường Đại học Thủy lợi

Sinh viên	Nguyễn Hồng Phúc
Mã số sinh viên	2351260680
Lớp	65TTNT
Pipeline	MFCC 13 + Endpoint + DTW
Kết quả baseline	80.0% (8/10)

Báo cáo được viết lại sau khi đối chiếu trực tiếp với notebook, figures và results.csv.

1. Mục tiêu và phạm vi thực hiện

Lab 2 chuyển các khái niệm của chương về biểu diễn tiếng nói thành một hệ nhận dạng từ đơn có thể chạy được. Các mục tiêu đã thực hiện trong notebook gồm:

- Đọc, resample và chuẩn hóa các file WAV về mono 16 kHz.
- Chia tín hiệu thành các frame ngắn và tính short-time energy, RMS, log-energy và ZCR.
- Dùng ngưỡng log-energy tương đối để xác định vùng speech và cắt silence ở hai đầu.
- Trích MFCC từ từng frame bằng pre-emphasis, Hamming window, FFT, Mel filterbank, log và DCT.
- Tự cài đặt local Euclidean distance, dynamic programming DTW, backtracking và chuẩn hóa theo path length.
- Xây dựng nearest-template recognizer với nhiều template cho mỗi nhãn.
- Đánh giá bằng accuracy, bảng Top-3, confusion matrix và hai thí nghiệm mở rộng.

Đề Lab cũng nêu short-time magnitude và autocorrelation/pitch. Trong notebook hiện tại, hai đại lượng này chưa được cài thành hàm hoặc hình minh họa riêng; vì vậy báo cáo chỉ mô tả chúng ở phần cơ sở lý thuyết và không nhận là kết quả thực nghiệm của code.

2. Môi trường và cấu trúc thư mục

2.1. Môi trường

- Python 3.13.7.
- NumPy, Librosa, SciPy, Matplotlib, Pandas và scikit-learn.
- Notebook Jupyter: Lab2_2351260680_NguyenHongPhuc.ipynb.
- Hệ điều hành thực nghiệm: Windows.

2.2. Cấu trúc dữ liệu

```
Lab02_2351260680_NguyenHongPhuc/
├── Lab 2.pdf
├── Lab2_2351260680_NguyenHongPhuc.ipynb
├── dataset_wav/
│   ├── khong/      # không
│   ├── mot/        # một
│   ├── hai/        # hai
│   ├── ba/         # ba
│   └── bon/        # bốn
├── figures/
│   ├── B_energy_zcr.png
│   ├── C_endpoint.png
│   ├── D_mfcc_heatmap.png
│   ├── D_mel_filterbank.png
│   ├── E_dtw_path.png
│   └── G_confusion_matrix_baseline.png
├── results.csv
├── report_Lab02.md
└── report_Lab02.pdf
```

2.3. Phân chia dữ liệu

Notebook sắp xếp file theo tên, chọn ba file đầu của mỗi lớp làm train và hai file cuối làm test. Vì tất cả file đều là cùng một bộ ghi âm của một người nói, đây là bài toán **speaker-dependent**.

Nhãn thư mục	Nhãn hiển thị	Tổng số	Train	Test
khong	không	5	3	2
mot	một	5	3	2
hai	hai	5	3	2
ba	ba	5	3	2
bon	bốn	5	3	2
Tổng		**25**	**15**	**10**

Việc tách train/test theo file, không dùng cùng một utterance ở cả hai tập, giúp tránh data leakage trong đánh giá baseline.

3. Cơ sở lý thuyết và pipeline

Pipeline được triển khai có thể tóm tắt như sau:

```
WAV -> mono/resample 16 kHz -> chuẩn hóa biên độ
  -> framing 25 ms, hop 10 ms, Hamming
  -> energy/RMS/ZCR -> endpoint detection
  -> pre-emphasis -> FFT -> Mel filterbank -> log -> DCT -> CMN
  -> chuỗi MFCC (T x 13)
  -> local Euclidean distance -> DTW -> nearest template -> nhãn
```

3.1. Framing và cửa sổ

Với tần số lấy mẫu Fs = 16000 Hz, frame 25 ms có:

$$L = F_s T_f = 16000 \times 0.025 = 400\{ mẫu\}.$$

Hop 10 ms có R = 160 mẫu, do đó hai frame liên tiếp chồng lấn 240 mẫu, tương đương 15 ms. Frame ngắn giúp tín hiệu tiếng nói gần dừng trong mỗi frame; hop nhỏ tạo chuỗi đặc trưng đủ dày theo thời gian.

Cửa sổ Hamming được áp dụng trước các phép tính miền thời gian và MFCC:

$$w[n] = 0.54 - 0.46\cos(\frac{2\pi n}{L-1}).$$

3.2. Các đặc trưng ngắn hạn

Với frame đã nhân cửa sổ x_r[n], code tính:

$$E_r = \sum_n x_r^2[n],$$

$$RMS_r = \sqrt{\frac{1}{L}\sum_n x_r^2[n]},$$

$$E_{dB,r} = 10\log_{10}(E_r + \epsilon),$$

$$Z_r = \frac{1}{2L}\sum_{n=1}^{L-1}|\operatorname{sgn}(x[n])-\operatorname{sgn}(x[n-1])|.$$

Energy/RMS phản ánh cường độ của frame. ZCR phản ánh mức độ đổi dấu: vùng hữu thanh thường có ZCR thấp hơn, phụ âm vô thanh thường có ZCR cao hơn, còn silence có energy rất thấp.

3.3. MFCC

Code sử dụng pre-emphasis:

$$y[n] = x[n] - 0.97x[n-1].$$

Sau đó, magnitude/power spectrum được gom qua 24 bộ lọc tam giác trên thang Mel. Với mỗi frame, các log-energy của filterbank được biến đổi bằng DCT để thu 13 hệ số MFCC. Cuối cùng, CMN được áp dụng theo từng hệ số trên toàn utterance:

$$\widetilde{M}_{k,t} = M_{k,t} - \frac{1}{T}\sum_{t=1}^{T}M_{k,t}.$$

MFCC có số chiều cố định 13 cho mỗi frame, nhưng số frame T thay đổi theo thời lượng phát âm. Đây là lý do cần DTW thay vì so sánh trực tiếp hai ma trận bằng khoảng cách Euclidean thông thường.

3.4. Khoảng cách và DTW

Với hai vector MFCC x_i và y_j, local distance là Euclidean:

$$C[i,j] = |x_i-y_j|_2.$$

Ma trận chi phí tích lũy được tính bằng quy hoạch động:

$$D[i,j] = C[i,j] + \min\{D[i-1,j], D[i,j-1], D[i-1,j-1]\}.$$

Ba bước tương ứng với kéo dài mẫu thứ nhất, kéo dài mẫu thứ hai hoặc tiến đồng thời ở cả hai chuỗi. Sau khi điền ma trận, code truy vết từ ô cuối về ô đầu để lấy optimal path P, rồi chuẩn hóa:

$$DTW_{norm}(X,Y) = \frac{D[N,M]}{|P|}.$$

Chuẩn hóa theo độ dài path làm giảm bất lợi của utterance dài, vì tổng chi phí của một chuỗi dài thường lớn hơn chỉ do có nhiều frame hơn.

4. Phân tích và kết quả theo các bước A-G

4.1. Bước A - Đọc dữ liệu và chuẩn hóa

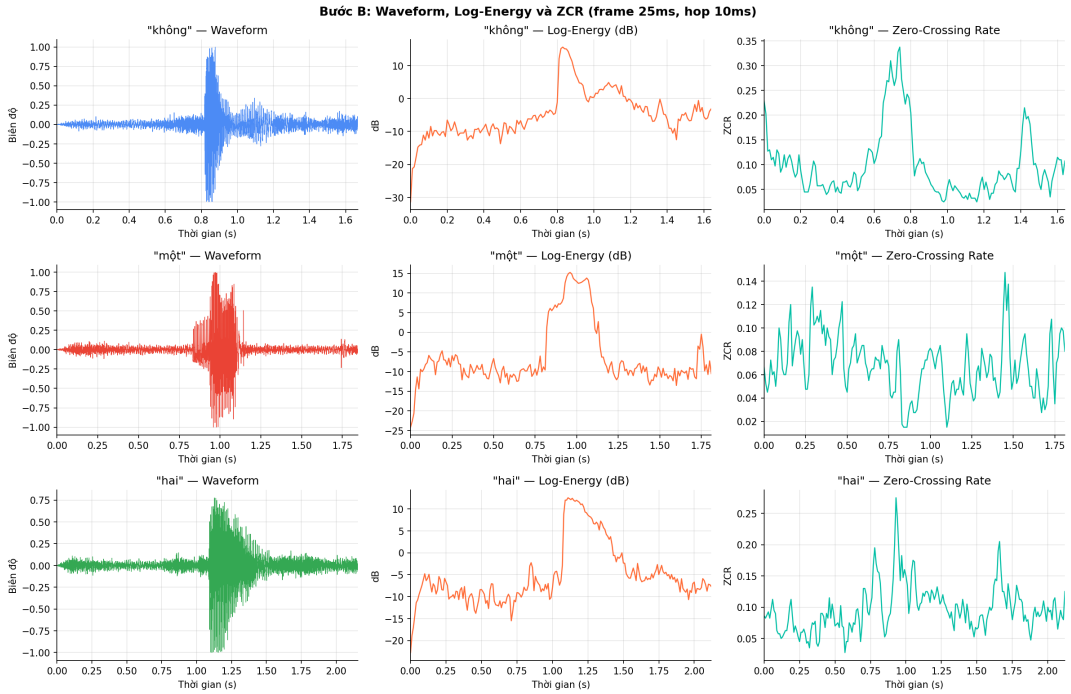
Hàm load_audio(path) gọi librosa.load(path, sr=16000, mono=True). Như vậy mọi file được đưa về cùng tần số lấy mẫu và một kênh. Sau đó tín hiệu được chuẩn hóa theo:

$$y_{norm}[n] = \frac{y[n]}{\max(|y[n]|)+10^{-9}}.$$

Chuẩn hóa này làm giảm ảnh hưởng của mức thu âm giữa các lần ghi. Nó không tạo thêm thông tin âm học và cũng không thay thế cho chuẩn hóa đặc trưng CMN.

4.2. Bước B - Energy, RMS và ZCR

Notebook minh họa ba từ không, một, hai bằng waveform, log-energy và ZCR với frame 25 ms, hop 10 ms.



Hình 1. Waveform, log-energy và ZCR của ba từ mẫu.

Với file khong_00.wav, notebook ghi nhận:

Đại lượng	Giá trị
Số frame	165
Log-energy lớn nhất	15.6 dB
Log-energy nhỏ nhất	-31.4 dB
ZCR lớn nhất	0.338
ZCR nhỏ nhất	0.025
Ngưỡng energy tương đối	-19.4 dB
Frame được xem là speech	162 (98%)
Frame được xem là silence	3 (2%)

Nhận xét:

- Khi biên độ tăng mạnh ở vùng phát âm, log-energy tăng rõ rệt.
- Các đoạn nguyên âm hữu thanh có energy cao và ZCR tương đối thấp.
- Các đoạn phụ âm vô thanh có thể có energy thấp hơn nhưng ZCR tăng.
- Silence có energy rất thấp; trong dữ liệu này khoảng silence đầu/cuối ngắn nên chỉ có ít frame nằm dưới ngưỡng.

Notebook chưa tính short-time magnitude sum(abs(frame)) và chưa có thí nghiệm so sánh trực tiếp magnitude với energy. Đây là phần có thể bổ sung ở phiên bản sau.

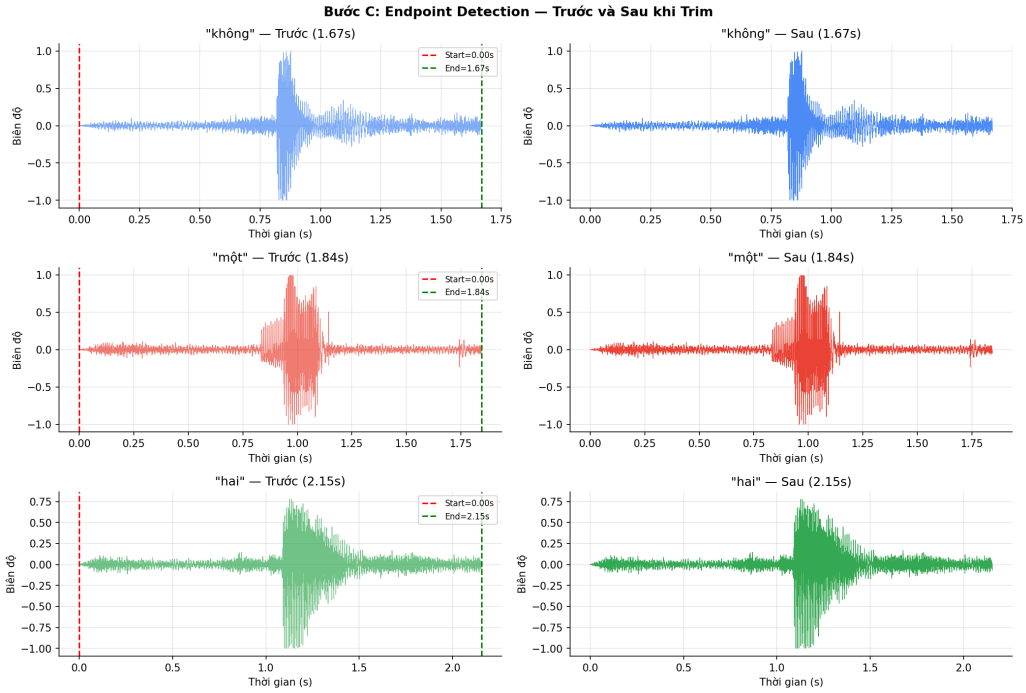
4.3. Bước C - Endpoint detection

Hàm trim_endpoint dùng librosa.effects.trim với:

Tham số	Giá trị	Ý nghĩa
top_db	35 dB	Ngưỡng tương đối so với mức năng lượng cực đại
frame_length	400 mẫu	Tương ứng 25 ms
hop_length	160 mẫu	Tương ứng 10 ms
margin_ms	50 ms	Đệm thêm sau khi tìm biên

Việc giữ margin 50 ms làm giảm nguy cơ cắt mất phụ âm đầu/cuối có energy thấp. Ba file minh họa đều bắt đầu và kết thúc gần sát vùng được giữ lại:

Từ	Trước trim	Sau trim	Lượng cắt
không	1.67 s	1.67 s	0 ms
một	1.84 s	1.84 s	0 ms
hai	2.15 s	2.15 s	0 ms



Hình 2. So sánh tín hiệu trước và sau endpoint detection.

Kết quả 0 ms không có nghĩa hàm trim không hoạt động; nó cho thấy với các file minh họa, mức năng lượng ở vùng đầu/cuối cùng với margin 50 ms đã làm khoảng giữ lại bao phủ gần như toàn bộ file. Do đó endpoint detection trong bộ dữ liệu này chủ yếu giữ sự nhất quán pipeline hơn là làm giảm đáng kể số frame.

Đề Lab gợi ý kết hợp ZCR để tinh chỉnh các âm vô thanh. Code hiện tại mới dùng energy heuristic; chưa dùng ZCR trong quyết định start/end.

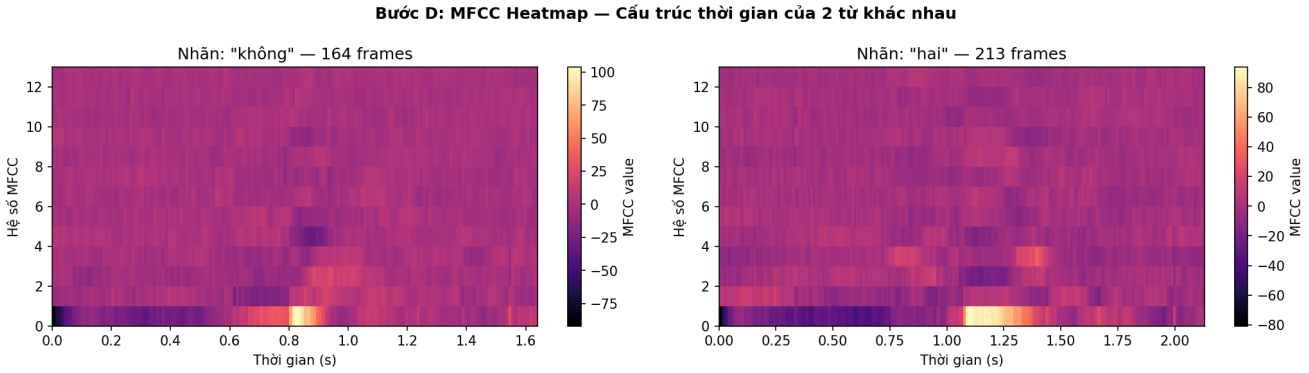
4.4. Bước D - MFCC và Mel filterbank

Các tham số MFCC trong code:

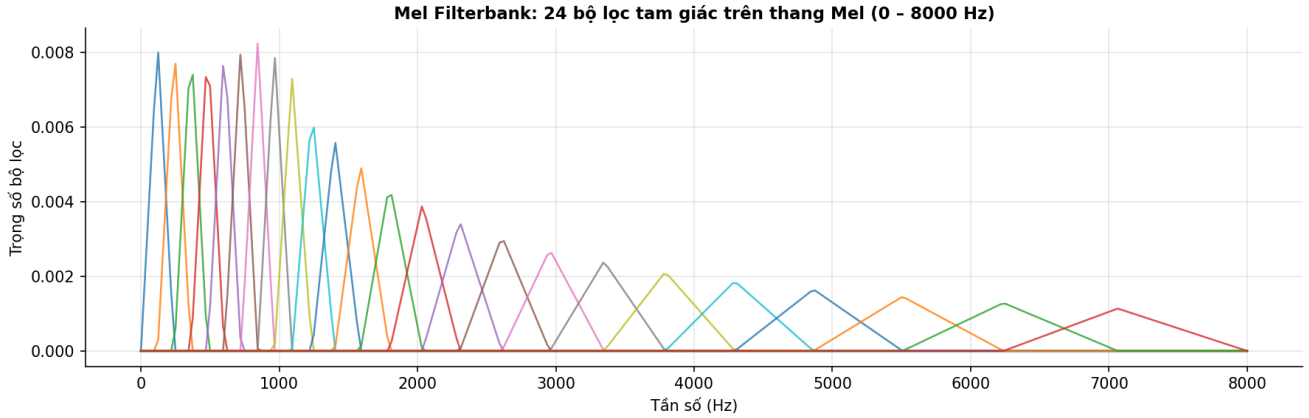
Tham số	Giá trị
Fs	16,000 Hz
Frame / hop	25 ms / 10 ms
Window	Hamming
Pre-emphasis	alpha = 0.97
N_FFT	512

Tham số	Giá trị
Số Mel filter	24
Số MFCC	13
center	False
Chuẩn hóa	CMN theo utterance

Kiểm tra với khong_00.wav sau trim cho ma trận kích thước **164 x 13**. Trong hình MFCC, từ không có 164 frame còn hai có 213 frame. Cùng số cột 13 nhưng khác số hàng là minh chứng trực tiếp cho biến thiên tốc độ và thời lượng phát âm.



Hình 3. Heatmap MFCC của hai từ khác nhau.



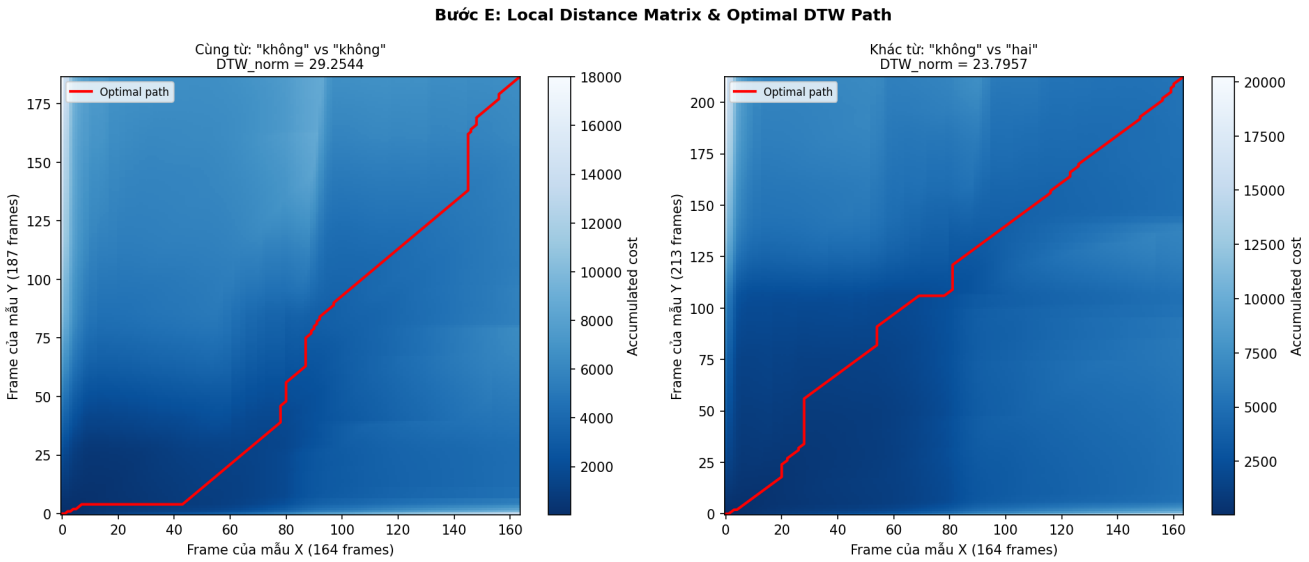
Hình 4. 24 bộ lọc tam giác trên thang Mel từ 0 đến 8 kHz.

Khoảng cách theo Hz giữa các bộ lọc rộng dần ở vùng cao vì thang Mel phân bố độ phân giải theo cảm nhận thính giác: tai nhạy hơn ở tần số thấp và kém phân biệt hơn khi tần số tăng. Log nén dynamic range của năng lượng filterbank; DCT decorrelate các log-energy và đưa chúng về các hệ số cepstral, trong đó các hệ số đầu mô tả đường bao phổ thô hơn.

4.5. Bước E - Local distance matrix và DTW

Code dtw_distance(X, Y) tự cài đặt hoàn toàn bằng NumPy. Ma trận local distance được tính bằng np.linalg.norm, không gọi hàm DTW có sẵn. Ma trận D có kích thước (N+1) x (M+1) với biên ngoài là vô cùng và D[0,0] = 0.

Hình dưới đây so sánh một cặp cùng từ không và một cặp khác từ không - hai.



Hình 5. Ma trận chi phí tích lũy và optimal path của hai cặp chuỗi MFCC.

Kết quả số trong notebook:

Cặp so sánh	Số frame	DTW_norm
không vs không	164 vs 187	29.2544
không vs hai	164 vs 213	23.7957

Về hình học, path của cặp cùng từ có các đoạn ngang/dọc do hai lần nói có tốc độ khác nhau; path của cặp khác từ cũng tiến đơn điệu từ góc đầu đến góc cuối. Tuy nhiên, cặp ví dụ này cho **DTW_norm khác từ nhỏ hơn cùng từ**, trái với kỳ vọng của một bộ nhận dạng tốt. Vì vậy không nên dùng riêng hai giá trị trên để kết luận DTW đã phân tách hoàn hảo; các giá trị cần được xem cùng kết quả nhận dạng trên toàn bộ tập test. Đây cũng là lý do confusion matrix và đánh giá nhiều template quan trọng.

4.6. Bước F - Nearest-template recognizer

Từ 15 file train, code tạo 3 template cho mỗi nhãn. Số frame sau trim của các template là:

Nhãn	Số frame của 3 template
không	164, 187, 203
một	182, 172, 183
hai	213, 171, 202
ba	237, 171, 180
bốn	189, 201, 227

Với file test X, hệ thống tính khoảng cách đến mọi template của một lớp và lấy giá trị nhỏ nhất:

$$D_w(X) = \min_r DTW_{norm}(X,T_{w,r}).$$

Nhãn cuối cùng là:

$$\hat{w} = \arg\min_w D_w(X).$$

Việc dùng 3 template thay vì một template giúp một lớp có nhiều đại diện hơn về tốc độ nói, biên độ và hình dạng phổ.

4.7. Bước G - Kết quả nhận dạng

Bảng sau được trích từ results.csv và giữ bốn chữ số thập phân cho các điểm DTW.

File test	Nhãn thật	Dự đoán	Top-1	Top-2	Top-3	Kết quả
khong_03.wav	không	không	20.6465	21.5484	23.2894	Đúng
khong_04.wav	không	không	21.4348	24.4315	25.0313	Đúng
mot_03.wav	một	một	22.9180	22.9698	23.5064	Đúng
mot_04.wav	một	bốn	23.8923	25.2617	26.6314	Sai
hai_03.wav	hai	hai	22.1286	25.2255	26.4899	Đúng

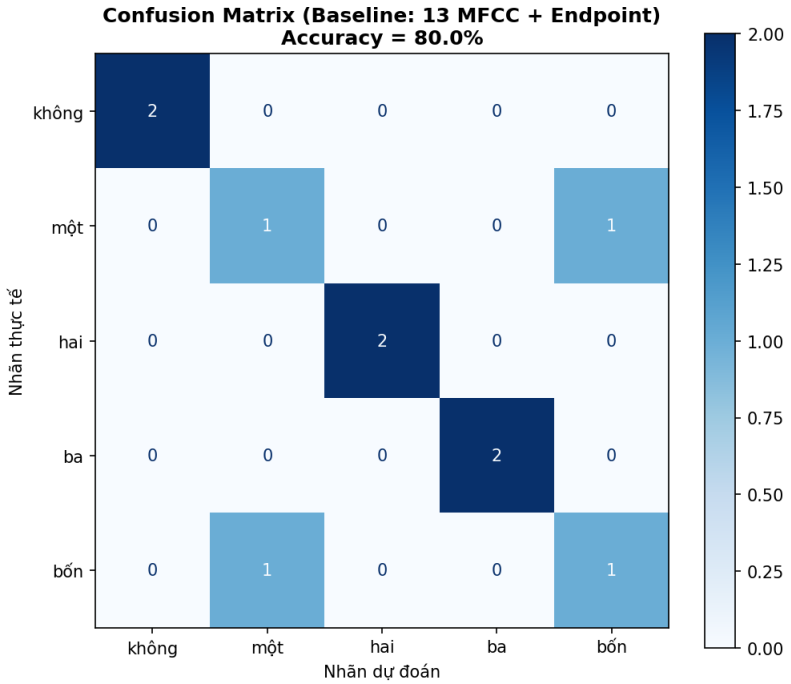
File test	Nhãn thật	Dự đoán	Top-1	Top-2	Top-3	Kết quả
hai_04.wav	hai	hai	22.3221	23.5101	27.0772	Đúng
ba_03.wav	ba	ba	20.4951	22.9191	25.3327	Đúng
ba_04.wav	ba	ba	23.3176	25.6325	28.1807	Đúng
bon_03.wav	bốn	bốn	20.9331	23.2483	24.5893	Đúng
bon_04.wav	bốn	một	25.9537	27.2467	27.6303	Sai

Accuracy baseline:

$$Accuracy = \frac{8}{10} \times 100\% = 80.0\%.$$

4.8. Confusion matrix và phân tích lỗi

Nhãn thật / Dự đoán	không	một	hai	ba	bốn
không	2	0	0	0	0
một	0	1	0	0	1
hai	0	0	2	0	0
ba	0	0	0	2	0
bốn	0	1	0	0	1



Hình 6. Confusion matrix của baseline MFCC 13 + endpoint + DTW.

Hai lỗi tạo thành nhầm lẫn hai chiều giữa một và bốn. Đây là cặp khó nhất trong bộ test nhỏ. Hai file lỗi đều có khoảng cách Top-1 và Top-2 khá gần nhau, cho thấy quyết định không có biên an toàn lớn. Các nguyên nhân phù hợp với dữ liệu hiện có là:

- hai lần phát âm có thể có nhịp và thời lượng tương tự;
- MFCC mô tả envelope phổ nên vẫn chịu ảnh hưởng của nguyên âm, phụ âm và cách phát âm;
- chỉ có 3 template cho mỗi lớp và 2 file test, nên một mẫu bất thường ảnh hưởng mạnh đến phần trăm accuracy;
- hệ thống speaker-dependent chưa học biến thiên người nói hoặc biến thiên kênh thu.

Để kiểm chứng sâu hơn, cần vẽ riêng waveform, MFCC và path của mot_04.wav và bon_04.wav; notebook hiện mới vẽ cặp minh họa không và hai.

5. Hai thí nghiệm mở rộng và kiểm toán code

5.1. E1 - Có và không endpoint detection

Notebook in ra:

Cấu hình được ghi trong output	Accuracy in ra
Có endpoint detection	80.0%
Không endpoint detection	80.0%

Tuy nhiên, sau khi rà soát code, kết quả này **chưa phải phép đối chứng hợp lệ**:

- Code có tạo templates_no_trim, nhưng dòng đánh giá lại gọi evaluate(test_files, templates) cho cả hai nhánh thay vì dùng templates_no_trim cho nhánh no-trim.
- Hàm recognize() luôn gọi trim_endpoint(path) cho file test. Vì vậy cả query và template thực tế đều vẫn đi qua pipeline trim.

Do đó, 80.0%/80.0% chỉ nên được ghi là output hiện tại của notebook, không nên diễn giải rằng endpoint detection chắc chắn không ảnh hưởng accuracy. Để sửa, cần truyền đúng template và cho phép recognize chọn có trim hay không, sau đó chạy lại toàn bộ thí nghiệm.

5.2. E2 - MFCC 13 so với MFCC 13 + Delta

Notebook ghi nhận:

Cấu hình	Accuracy ghi nhận
MFCC 13	80.0%
MFCC 13 + Delta 13	70.0%

Delta chứa tốc độ thay đổi của MFCC theo thời gian, nên về lý thuyết có thể giúp mô tả động học. Trong dữ liệu này, accuracy ghi nhận giảm 10 điểm phần trăm. Tuy nhiên, code E2 cũng có một khác biệt cần lưu ý: mfcc_with_delta không truyền center=False vào librosa.feature.mfcc, trong khi baseline có center=False. Như vậy E2 không chỉ thêm Delta mà còn thay đổi cách padding/framing. Kết luận chắc chắn về tác dụng của Delta chỉ nên đưa ra sau khi giữ toàn bộ tham số framing giống baseline.

5.3. Bảng kiểm tra tính nhất quán

Hạng mục	Trạng thái	Nhận xét
Resample mono 16 kHz	Đạt	Dùng librosa.load(..., sr=FS, mono=True)
Train/test không trùng file	Đạt	3 train + 2 test mỗi lớp
Energy/RMS/ZCR	Đạt	Có hàm, hình và số liệu
Short-time magnitude	Chưa có	Chưa tính sum(abs(frame))
Autocorrelation/pitch	Chưa có	Chưa cài trong notebook
Endpoint trim	Có	top_db=35, margin 50 ms
MFCC baseline	Đạt	24 Mel, 13 MFCC, alpha 0.97, CMN
DTW tự cài đặt	Đạt	Euclidean, DP, backtracking, path normalization
Top-3 và CSV	Đạt	Có results.csv cho 10 file test
E1	Cần sửa	Dùng nhầm template và vẫn trim query
E2	Cần kiểm soát lại	Khác center giữa baseline và Delta

6. Trả lời câu hỏi báo cáo

Câu 1. Vì sao không nên dùng toàn bộ waveform làm template khi hai utterance có thời lượng khác nhau?

Waveform là chuỗi mẫu theo thời gian. Nếu so sánh trực tiếp bằng Euclidean distance, hai chuỗi thường phải có cùng số mẫu và các âm tương ứng phải nằm ở cùng vị trí. Cùng một từ nhưng người nói nhanh hoặc chậm sẽ tạo số mẫu khác nhau, khiến khoảng cách lớn dù nội dung giống nhau. DTW giải quyết bằng một ánh xạ phi tuyến, cho phép một đoạn của chuỗi này khớp với nhiều frame của chuỗi kia.

Câu 2. Vai trò của short-time energy và ZCR trong endpoint detection?

Energy/RMS cho biết mức cường độ và thường dùng để phân biệt speech với silence. ZCR cho biết mức độ đổi dấu: voiced thường có tính tuần hoàn và ZCR thấp hơn, trong khi unvoiced/fricative có thể có ZCR cao dù energy không lớn. Kết hợp hai đặc trưng giúp giữ lại phụ âm vô thanh ở biên, tránh cắt quá mạnh chỉ dựa trên energy. Notebook hiện mới dùng energy trong hàm trim, còn ZCR được dùng để quan sát và nhận xét.

Câu 3. Vì sao Mel filterbank có khoảng cách theo Hz rộng dần khi tần số tăng?

Thang Mel mô phỏng độ phân giải phi tuyến của tai người. Ở vùng tần số thấp, tai phân biệt được các thay đổi nhỏ nên các bộ lọc được đặt dày và hẹp. Ở vùng cao, độ phân giải cảm nhận thấp hơn nên các bộ lọc rộng dần theo Hz. Điều này tạo biểu diễn phù hợp hơn với nhận thức âm thanh so với chia đều trên thang Hz.

Câu 4. Log trong MFCC có tác dụng gì? DCT tạo ra các hệ số nào?

Log nén dynamic range của năng lượng filterbank, biến các chênh lệch nhân thành gần chênh lệch cộng và gần hơn với đặc tính cảm nhận cường độ của tai. DCT biến vector log-energy của 24 filter thành các hệ số cepstral MFCC. Các hệ số thấp mô tả đường bao phổ tổng quát; các hệ số cao chứa biến thiên chi tiết hơn và thường nhạy hơn với nhiễu.

Câu 5. Ý nghĩa của bước ngang, dọc và chéo trong ma trận DTW?

- Bước chéo (i-1, j-1): hai chuỗi cùng tiến một frame, tương ứng tốc độ gần nhau.
- Bước dọc (i-1, j): chuỗi X tiến trong khi Y giữ lại frame hiện tại, biểu diễn một phía bị kéo dài hoặc phía kia nói nhanh hơn.
- Bước ngang (i, j-1): chuỗi Y tiến trong khi X giữ lại frame hiện tại, có ý nghĩa ngược lại.

Ba bước phải bảo toàn thứ tự thời gian và tạo một đường đi đơn điệu từ đầu đến cuối.

Câu 6. Vì sao chuẩn hóa DTW cost theo path length?

Tổng cost tăng theo số cặp frame. Một utterance dài hoặc path có nhiều bước sẽ dễ có tổng cost lớn hơn ngay cả khi sai khác trung bình mỗi frame nhỏ. Chia cho |P| chuyển tổng chi phí thành chi phí trung bình trên mỗi bước, giúp so sánh các utterance có độ dài khác nhau công bằng hơn.

Câu 7. Nêu ít nhất ba nguyên nhân làm cùng một từ có MFCC khác nhau giữa hai lần nói.

Các nguyên nhân chính gồm:

- Tốc độ nói khác nhau làm số frame và tiến trình âm học thay đổi.
- Âm lượng hoặc khoảng cách đến micro khác nhau làm thay đổi năng lượng phổ.
- Vị trí micro, phòng và nhiễu nền tạo đáp ứng tần số khác nhau.
- Ngữ điệu, cảm xúc hoặc trọng âm khác nhau làm thay đổi F0 và formant.
- Cách phát âm phụ âm đầu/cuối và mức kéo dài nguyên âm không giống nhau.

Pre-emphasis, CMN và DTW làm giảm một phần các sai khác này nhưng không loại bỏ hoàn toàn.

Câu 8. Phân tích cặp từ dễ nhầm nhất từ confusion matrix.

Cặp nhầm lẫn là một và bốn: mot_04.wav bị đoán thành bốn, còn bon_04.wav bị đoán thành một. Hai lỗi có tính đối xứng, phù hợp với việc hai mẫu test có các điểm DTW gần nhau giữa hai lớp. Với mot_04.wav, Top-1 là bốn = 23.8923 còn một = 25.2617; với bon_04.wav, Top-1 là một = 25.9537 còn bốn = 27.2467. Khoảng cách chênh khoảng 1.3-1.4, nhỏ so với quyết định chắc chắn.

Waveform và MFCC của từng mẫu lỗi chưa được notebook vẽ riêng, nên nguyên nhân âm học chỉ có thể kết luận ở mức giả thuyết: nhịp nói tương tự, envelope phổ có vùng tương đồng và dữ liệu quá nhỏ. Phân tích bổ sung nên vẽ hai heatmap MFCC lỗi và hai optimal path với toàn bộ template của hai lớp.

Câu 9. Hạn chế khi nhận dạng người nói mới chưa có template là gì? Chương 3 giải quyết thế nào?

DTW nearest-template là hệ speaker-dependent. MFCC không chỉ chứa thông tin của từ mà còn chứa biến thiên người nói như F0, formant, khẩu hình, tốc độ và kênh thu. Nếu người nói mới không có template, khoảng cách đến mọi template cũ có thể lớn và hệ thống vẫn buộc phải chọn một nhãn gần nhất, không có cơ chế tổng quát hóa tốt.

Để giải quyết, có thể dùng mô hình âm học học từ nhiều người nói như GMM-HMM hoặc DNN-HMM, kết hợp nhiều dữ liệu train và mô hình hóa biến thiên theo thời gian. Các mô hình đó học phân bố của đặc trưng thay vì ghi nhớ vài template cụ thể. Với bài toán nhỏ, có thể cải thiện thêm bằng chuẩn hóa speaker, data augmentation và thêm dữ liệu cross-speaker.

7. Kết luận

Notebook đã triển khai được phần cốt lõi của một recognizer từ đơn cổ điển: xử lý frame, trực quan hóa energy/ZCR, MFCC, DTW tự cài đặt, nearest-template và đánh giá bằng confusion matrix. Baseline **MFCC 13 + endpoint + DTW** đạt **80.0% trên 10 file test**, trong đó không, hai, ba đạt 100% trên hai mẫu test của mỗi lớp, còn lỗi tập trung ở cặp một - bốn.

Các kết quả trực quan cho thấy MFCC tạo ra chuỗi đặc trưng có số chiều cố định nhưng độ dài thay đổi, và DTW là cơ chế phù hợp để căn chỉnh biến thiên tốc độ nói. Tuy vậy, dữ liệu chỉ gồm 25 file của một người nói nên accuracy chưa thể đại diện cho khả năng nhận dạng độc lập người nói.

Ba điểm cần ưu tiên nếu tiếp tục hoàn thiện:

- Sửa E1 để hai nhánh thực sự khác nhau ở endpoint detection và chạy lại kết quả.
- Giữ center=False nhất quán khi so sánh MFCC 13 với MFCC + Delta.
- Bổ sung short-time magnitude, autocorrelation/pitch và thí nghiệm cross-speaker.

Với các lưu ý trên, báo cáo phản ánh đúng cả phần đã hoàn thành và giới hạn hiện tại của code Lab2, thay vì chỉ trình bày accuracy mà bỏ qua tính hợp lệ của phép đối chứng.

8. Tài liệu tham khảo

- Huang, X., Acero, A., & Hon, H.-W. *Spoken Language Processing*. Prentice Hall, 2001.
- Rabiner, L. R., & Schafer, R. W. *Theory and Applications of Digital Speech Processing*. Pearson, 2011.
- Jurafsky, D., & Martin, J. H. *Speech and Language Processing*. Prentice Hall, 2008.
- CSE457 - Xử lý âm thanh và tiếng nói, *Lab 2: Đặc trưng tiếng nói và nhận dạng bằng DTW*, Trường Đại học Thủy lợi.