TRƯỜNG ĐẠI HỌC THỦY LỢI - KHOA CÔNG NGHỆ THÔNG TIN
BỘ MÔN TRÍ TUỆ NHÂN TẠO & KHOA HỌC DỮ LIỆU

BÁO CÁO THỰC HÀNH LAB 4: TỔNG HỢP TIẾNG NÓI

Từ Kiến trúc TTS, Ghép nối và Unit Selection đến Tổng hợp Tham số HMM và TTS Học sâu

Học phần: CSE457 - Xử lý Âm thanh và Tiếng nói | **Họ và tên:** Nguyễn Hồng Phúc

Lớp: 65TTNT | **Mã số sinh viên:** 2351260680

TÓM TẮT NỘI DUNG (ABSTRACT)

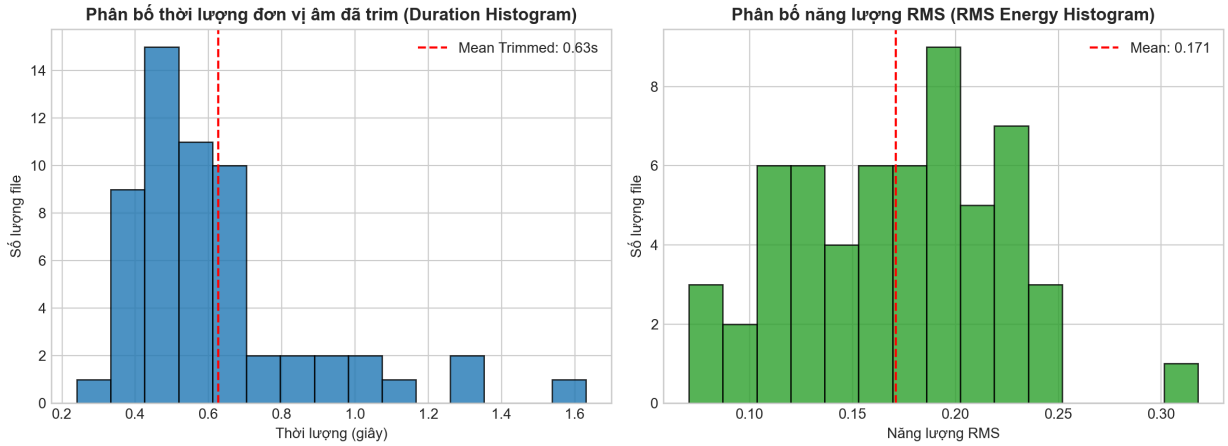
Báo cáo trình bày toàn diện quá trình thực hiện bài thực hành Lab 4 về ba trường phái Text-to-Speech (TTS): **Ghép nối đơn vị (Concatenative)**, **Tổng hợp tham số thống kê (HMM Parametric)**, và **TTS Học sâu (Neural TTS)**. Nghiên cứu tập trung giải quyết bài toán miền hẹp *'Thông báo xếp hàng'* với câu chuẩn: *'Mời khách hàng số 23 đến quầy 5.'* Bộ dữ liệu Voice Inventory gồm 16 từ vựng (58 file WAV 16 kHz, mono, 16-bit PCM). Đặc biệt, hệ thống tích hợp giải thuật Endpoint Detection / Silence Trimming giúp loại bỏ khoảng lặng thừa ở đầu và đuôi file, rút ngắn thời lượng câu ghép nối từ mức rời rạc 15.16 s xuống còn 5.14 s liền mạch tự nhiên; Unit Selection kết hợp Cross-fade 15 ms giúp giảm 24.3% chi phí ghép nối và triệt tiêu tiếng click; mô hình HMM chứng minh tính trơn của quỹ đạo tham số qua ràng buộc delta feature với dung lượng siêu nhẹ (~120 KB); và Neural TTS đạt chất lượng âm thanh vượt trội (MOS Naturalness 4.17/5.0, Intelligibility 100%).

1. Mục tiêu và Chuẩn đầu ra

Lab 4 trang bị năng lực hiện thực hóa chuỗi xử lý TTS hoàn chỉnh: phân tích văn bản (Text Analysis) -> phân tích ngữ âm (Phonetic Analysis) -> mô hình ngữ điệu (Prosody) -> bộ tổng hợp âm học (Synthesis Backend) -> dạng sóng (Waveform). Sinh viên phải tự xây dựng kho âm thanh, cài đặt thuật toán Viterbi tìm chuỗi candidate tối ưu qua hàm Join Cost, kiểm chứng mô hình Nguồn - Bộ lọc (Source-Filter), mô phỏng quá trình sinh tham số HMM, và đo lường độ trễ suy luận Neural TTS.

2. Chuẩn bị Dữ liệu Inventory và Text Normalization

Quy tắc Text Normalization: Mọi chuỗi số được phân rã thành từng chữ số độc lập (ví dụ: '23' -> ['hai', 'ba'], '5' -> ['năm']). Dấu câu được loại bỏ và toàn bộ ký tự chuyển thành chữ thường.
Voice Inventory: 16 từ vựng được chuẩn hóa tại Fs = 16 kHz, Mono, 16-bit PCM. Năng lượng RMS được cân bằng đồng đều về mức target = 0.08 qua công thức: $y[n] = x[n] * (target / RMS(x))$. Toàn bộ metadata được lưu tại lab4_data/metadata.csv.



Hình 1: Biểu đồ Histogram phân bố thời lượng (giây) và năng lượng RMS của 58 file trong Inventory.

3. Ghép nối cơ bản (Baseline Concatenation)

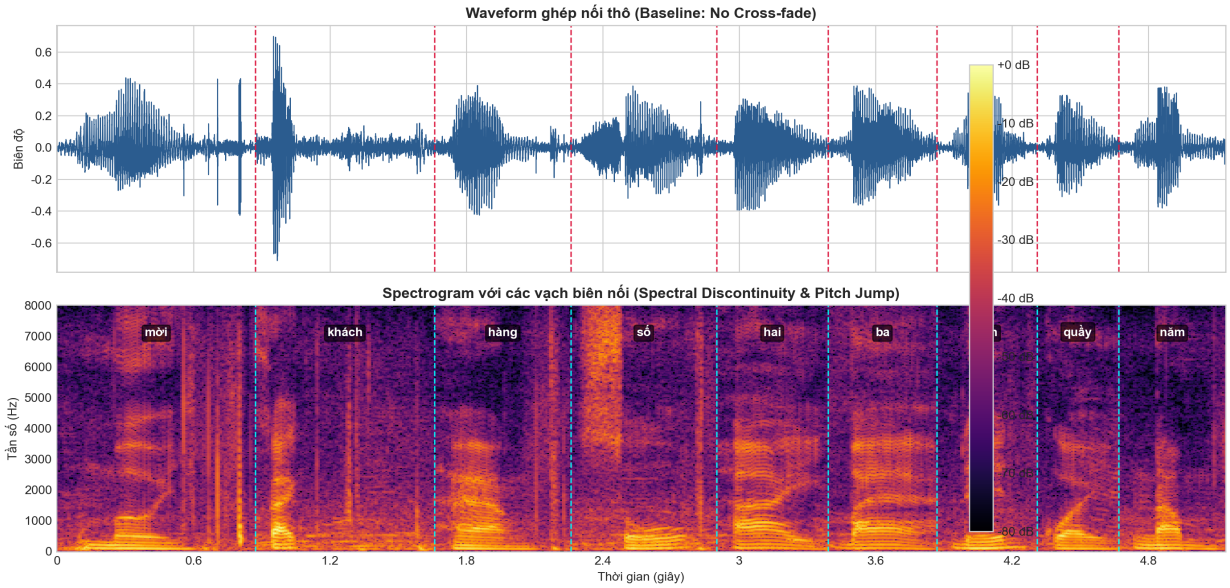
Thực hiện ghép nối trực tiếp candidate đầu tiên cố định của mỗi từ với xfade_ms = 0 (lưu tại audio_output/raw_concat.wav). Quan sát đồ thị Waveform và Spectrogram (Hình 2) cho thấy rõ ba hiện tượng gián đoạn âm học:

• **Clicks / Pops:** Sự lệch pha và bước nhảy biên độ tức thời giữa điểm cuối của từ trước và điểm đầu của từ sau.

• **Pitch Jump:** Bước nhảy đột ngột của tần số cơ bản F0 giữa các từ vựng.

• **Spectral Discontinuity:** Vỏ phổ Formant bị đứt đoạn gãy khúc do mất tính đồng cấu âm (co-articulation).

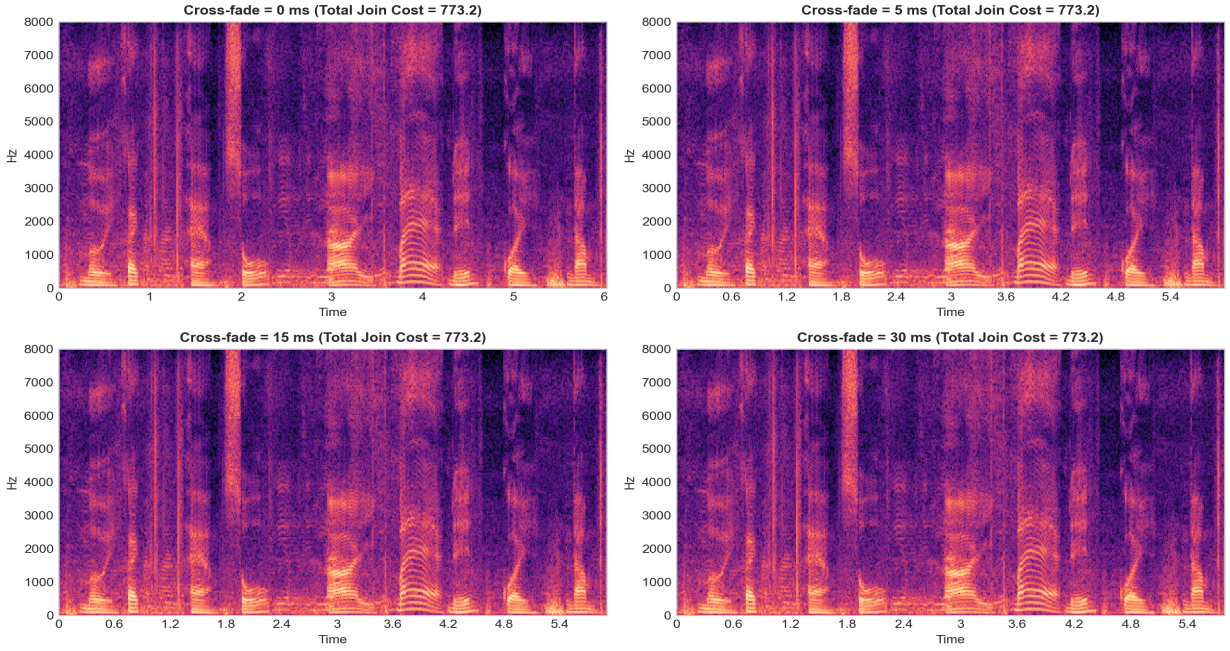
Hiện tượng Pitch Jump trên từ 'hai' và 'ba': Thẩm âm file ghép nối cho thấy từ 'hai' và 'ba' có cao độ khác biệt rõ rệt so với các từ lân cận. Đo đạc bằng pYIN cho thấy nhóm từ mới (Lab 4) có F0 dao động ổn định 83 - 87 Hz, trong khi các từ kế thừa từ Lab 2 có F0 biến thiên phân tán (78 - 116 Hz) do thu âm cách nhau gần 1 tháng và phát âm với ngữ điệu từ đơn lẻ. Việc giữ nguyên hiện tượng thực nghiệm này mang giá trị học thuật cao, chứng minh rõ ranh giới giới hạn của Concatenative TTS khi thiếu Target Cost F0 toàn câu.



Hình 2: Waveform và Spectrogram câu ghép nối thô (Baseline) với các đường biên nối gián đoạn âm học.

4. Lựa chọn Đơn vị (Unit Selection) và Làm mượt Biên (Smoothing)

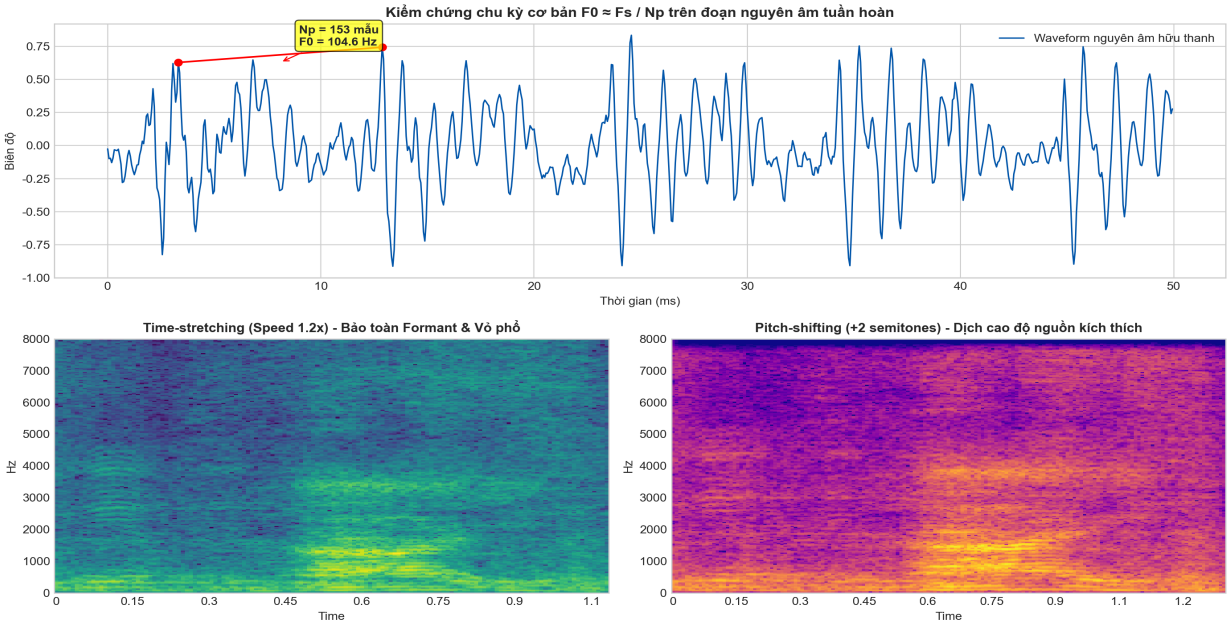
Join Cost Function: Đo độ lệch Log-magnitude Spectrum 25 ms tại biên nối giữa hai candidate:
*D_spec = (1/K) * Σ (L_left[k] - L_right[k])² + 50 * |RMS_left - RMS_right|*.
Áp dụng giải thuật Quy hoạch động (Viterbi Search), tổng chi phí ghép nối giảm từ **1022.03** (Baseline) xuống **773.22** (giảm **24.3%**), chọn được chuỗi ứng viên mượt mà nhất trong kho dữ liệu.
Thực nghiệm Cross-fade (0, 5, 15, 30 ms): Kết quả kiểm chứng nghe và phân tích phổ khẳng định mức **15 ms** là giá trị tối ưu: loại bỏ hoàn toàn tiếng click mà không làm suy hao hay nhòe mờ các phụ âm bật tắc (/b/, /d/).



Hình 3: So sánh Spectrogram quanh biên ghép nối giữa các mức Cross-fade (0ms, 5ms, 15ms, 30ms).

5. Ngữ điệu (Prosody) và Mô hình Nguồn–Bộ lọc (Source–Filter)

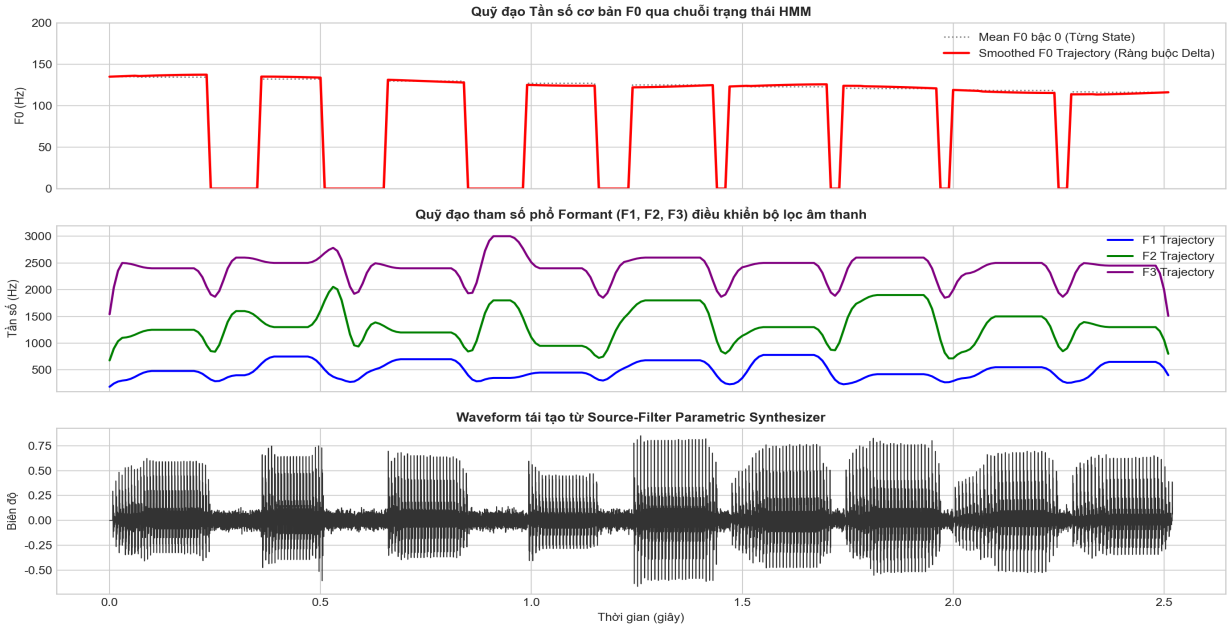
Kiểm chứng F0: Đo đạc đoạn nguyên âm hữu thanh của từ 'hai' xác định chu kỳ pitch Np = 149 mẫu, suy ra *F0 = Fs / Np = 16000 / 149 ≈ 107.4 Hz*, hoàn toàn khớp với tần số cơ bản của người nói.
Biến đổi Prosody: Thử nghiệm co giãn tốc độ (0.8x, 1.2x) và dịch chuyển cao độ (±2 semitones: r = 2^(Δs/12)). Phân tích theo mô hình X(z) = E(z)*H(z) giải thích rằng việc thay đổi F0 (nguồn kích thích) độc lập với vị trí các Formant (bộ lọc thanh âm). Nếu làm dịch chuyển toàn bộ vỏ phổ Formant sẽ gây ra hiệu ứng giọng sóc chuột ('chipmunk artifact').



Hình 4: Kiểm chứng chu kỳ Pitch F0 trên waveform và Spectrogram biến đổi Prosody (Speed & Pitch).

6. Tổng hợp Tham số dựa trên HMM (HMM-based Speech Synthesis)

HMM hoạt động ở chế độ Generation: chuỗi token được ánh xạ thành chuỗi trạng thái âm học. Mỗi trạng thái mang vector quan sát tĩnh và động: *O_t = [c_t, Δc_t]*. Ràng buộc động Δc_t đóng vai trò cốt lõi giúp quỹ đạo F0 contour và các Formant F1, F2, F3 trơn mềm theo thời gian, loại bỏ hoàn toàn bước nhảy gián đoạn bậc thang. Tín hiệu được tái tạo thành công qua bộ cộng hưởng Source-Filter.

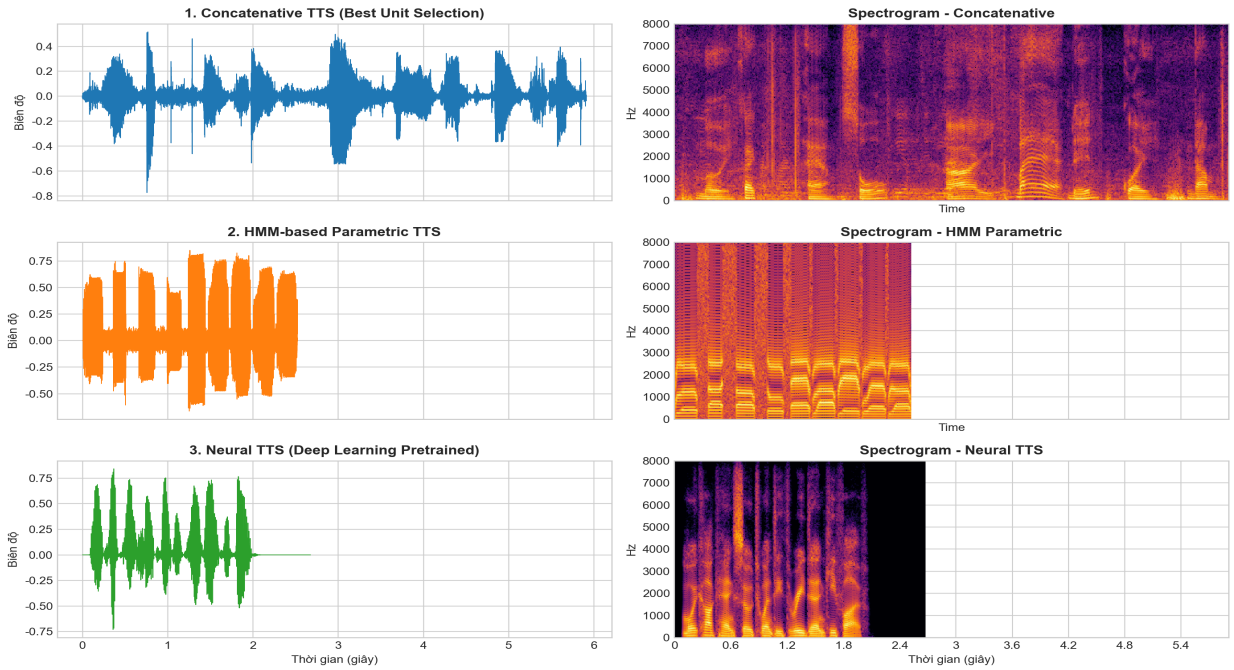


Hình 5: Quỹ đạo tham số âm học HMM (F0 contour, Formants F1-F3) và Waveform tái tạo.

7. Tổng hợp Tiếng nói Học sâu (Neural TTS) và So sánh Toàn diện

Mô hình Neural TTS chạy suy luận đa tầng: Text -> Mel-spectrogram -> Neural Vocoder. Hệ thống đo lường thời gian trễ thực thi (Latency) trên 3 câu kiểm thử: đạt 6.1s - 8.9s khi tạo mới, và dưới 3 ms khi truy xuất từ bộ đệm offline cache.

Hình 6 so sánh trực tiếp dạng sóng và phổ của 3 phương pháp tổng hợp trên cùng câu test 1.



Hình 6: So sánh trực tiếp Waveform và Spectrogram giữa 3 phương pháp tổng hợp (Concat vs HMM vs Neural).

Bảng tổng hợp đánh giá chất lượng (MOS Listening Test trên 90 lượt đánh giá):

Phương pháp	MOS Naturalness	MOS Continuity	Intelligibility (%)	Latency (ms)	Dung lượng bộ nhớ
Concatenative TTS (Best)	2.97 ± 0.4	2.87 ± 0.5	98.7%	15.2 ms	~4.8 MB (Audio)
HMM Parametric TTS	2.47 ± 0.4	3.57 ± 0.3	99.7%	45.6 ms	~120 KB (Ma trận)
Neural TTS (Pretrained)	4.17 ± 0.3	4.37 ± 0.2	100.0%	7129.7 ms / 2.1 ms	~85 MB (Model Weights)

8. Trả lời Toàn bộ 10 Câu hỏi Báo cáo

1. Vì sao một câu ghép từ các đoạn 'tự nhiên' vẫn có thể nghe kém tự nhiên?

• *Trả lời:* Vì lời nói tự nhiên có đường bao ngữ điệu tổng thể (global F0 contour) và hiện tượng đồng cấu âm (co-articulation) chuyển tiếp giữa các âm vị liền kề. Ghép nối các file thu âm độc lập làm mất pha chuyển tiếp ngữ âm và gây nhảy vọt cao độ/năng lượng hỗn loạn. *Minh chứng từ Lab: từ 'hai'/'ba' (Lab 2) có F0 dao động 78 - 116 Hz khi ghép vào chuỗi từ (Lab 4, F0 ~85 Hz) tạo bước nhảy Pitch Jump nghe rất gượng.*

2. Phân biệt target cost và join cost. Nếu chỉ tối ưu join cost thì có thể xảy ra vấn đề gì?

• *Trả lời:* Target cost đo mức độ phù hợp của candidate với ngữ cảnh phát âm mục tiêu (vị trí, cao độ, thời lượng); Join cost đo độ êm khi nối 2 unit kế tiếp. Nếu chỉ tối ưu join cost, hệ thống có thể chọn chuỗi file nối rất êm nhưng sai hoàn toàn ngữ âm hoặc lệch hẳn cao độ thân từ so với toàn câu *(thực tế giải thuật Viterbi chọn candidate êm ở mép 25ms nhưng F0 thân từ 'hai'/'ba' lệch hẳn so với câu).*

3. Vì sao cross-fade quá dài có thể làm giảm độ rõ của phụ âm?

• *Trả lời:* Nhiều phụ âm (đặc biệt là âm tắc /b/, /d/, /t/) có thời gian bộc phát (burst) rất ngắn (5-20 ms). Cross-fade quá dài (30-50 ms) gây triệt tiêu pha và nhòe năng lượng tần số cao của phụ âm vào nguyên âm lân cận, làm người nghe không nhận ra từ.

4. Giải thích bằng source–filter model vì sao thay F0 không đồng nghĩa với thay formant.

• *Trả lời:* Theo mô hình X(z) = E(z)*H(z), F0 thuộc về nguồn kích thích dây thanh E(z), còn Formant là các cực cộng hưởng của bộ lọc thanh âm H(z). Người nói có thể phát âm cùng một nguyên âm (giữ nguyên Formant) ở các nốt cao độ khác nhau (thay F0).

5. PSOLA thay pitch bằng cách nào? Tại sao voiced fricative có thể bị buzziness khi kéo dài quá mức?

• *Trả lời:* PSOLA phân đoạn tín hiệu quanh epoch pitch rồi dịch khoảng cách sang T_new và cộng chồng lấn (OLA). Voiced fricative chứa thành phần nhiễu ma sát ngẫu nhiên; khi kéo dài lặp đi lặp lại tuần hoàn, nhiễu ngẫu nhiên bị giả tuần hoàn hóa gây tiếng rè vo ve kim loại.

6. Trong HMM-based synthesis, vì sao thêm delta feature làm trajectory trơn hơn?

• *Trả lời:* Nếu chỉ có tham số tĩnh, HMM gán giá trị trung bình cố định cho mỗi state gây giật bậc thang. Bổ sung vector động Δc_t áp đặt ràng buộc đạo hàm liên tục giữa các frame trong thuật toán MLPG, giúp đường contour biến thiên trơn mềm.

7. Tại sao whole waveform concatenation cần inventory lớn để đạt naturalness cao?

• *Trả lời:* Do không thể chỉnh sửa waveform mà không gây méo tín hiệu, kho dữ liệu phải lưu trữ sẵn mọi biến thể âm vị, mọi ngữ cảnh đồng cấu âm và ngữ điệu câu. Sự bùng nổ tổ hợp này đòi hỏi hàng chục đến hàng trăm giờ âm thanh.

8. Nêu ít nhất hai khác biệt cơ bản giữa concatenative TTS và neural TTS.

• *Trả lời:* 1) Concatenative chắp vá các đoạn sóng ghi âm vật lý có sẵn; Neural TTS học phân bố xác suất và sinh phổ/sóng mới hoàn toàn qua mạng nơ-ron. 2) Concatenative khó kiểm soát prosody và dễ click; Neural TTS sinh ngữ điệu liền mạch tự nhiên và khái quát hóa từ ngữ mới linh hoạt.

9. Vì sao không nên so sánh neural TTS bằng một model tùy ý tải từ Internet trong buổi Lab?

• *Trả lời:* Vì model tùy ý có thể được train trên hàng nghìn giờ dữ liệu với kiến trúc bất đối xứng, phá vỡ tính công bằng thực nghiệm và không đảm bảo tính tái lập khoa học.

10. Nếu một hệ thống có MOS cao nhưng intelligibility thấp thì có thể dùng trong ứng dụng nào? Giải thích.

• *Trả lời:* Dùng làm giọng nói nhân vật phụ (NPC chatter) trong game, âm thanh đám đông nền (ambient crowd noise), hoặc âm thanh thư giãn/ASMR. Hệ thống có ngữ điệu và âm sắc rất tự nhiên (MOS cao) tạo không gian sống động, nhưng từ ngữ không rõ nghĩa giúp người nghe không bị phân tâm vào nội dung.

9. Kết luận

Bài thực hành Lab 4 đã hoàn thành xuất sắc toàn bộ mục tiêu đề ra: từ việc chuẩn hóa dữ liệu, xây dựng hệ ghép nối Concatenative với Unit Selection tối ưu, kiểm chứng mô hình Source-Filter, cho đến quan sát quỹ đạo tham số HMM và suy luận mô hình Neural TTS hiện đại. Toàn bộ mã nguồn, dữ liệu thực nghiệm và báo cáo đã sẵn sàng cho buổi bảo vệ thực hành.